

Machine Learning

12강

딥러닝 (2)

컴퓨터과학과 이관용 교수

학습목차

01 기본 순환 신경망(RNN)

02 LSTM과 GRU

1

기본 순환 신경망(RNN)

순환 신경망의 필요성

○ 순차 데이터 sequential data


- 순서 정보를 가진 데이터 → 예: 음성, 문장, 동영상, 주식 시세 등
- 특징
 - ✓ 데이터의 출현 순서가 중요
 - ✓ 데이터의 길이가 가변적
 - ✓ 데이터의 요소 사이에 문맥적 의존성 존재 → 이전 내용의 기억이 필요

○ “순환 신경망 RNN: recurrent neural networks”


- 시간에 따라 순차적으로 제공되는 데이터를 다루기 위한 모델
 - ✓ 응용 분야 → 기계번역, 음성 처리 등

기본적인 RNN 구조

“vanilla RNN”



전방향 신경망



순환 신경망

특정 시간 t 에서의 은닉층의 상태


$$h_t = f_W(h_{t-1}, x_t)$$

↓

$$W = (W_{xh}, W_{hh}, W_{hy})$$

RNN의 표현 방법

○ 축약된 표현



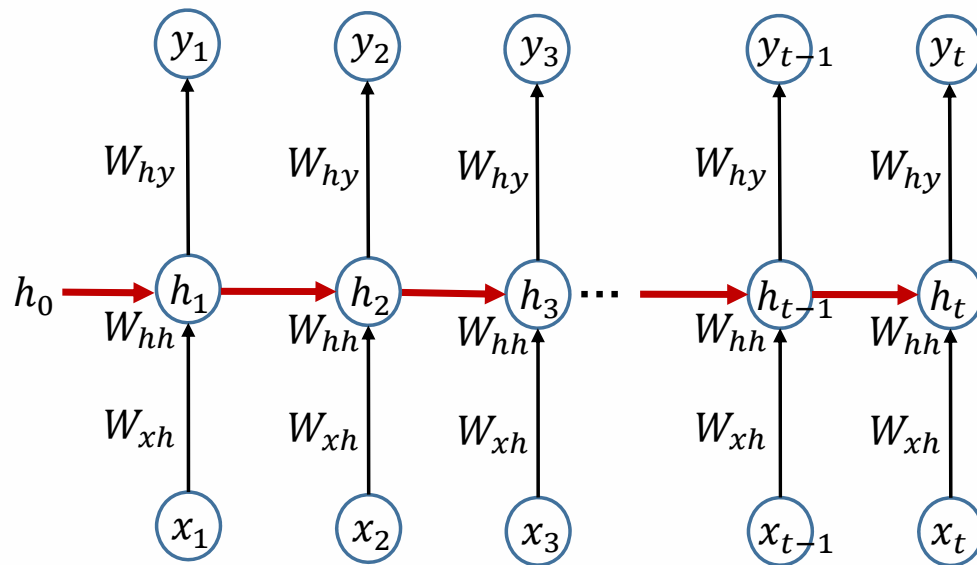
$$\begin{aligned}
 h_t &= f_W(h_{t-1}, x_t) \\
 &= f_W(f_W(h_{t-2}, x_{t-1}), x_t) \\
 &= f_W(f_W(f_W(h_{t-3}, x_{t-2}), x_{t-1}), x_t) \\
 &\quad \vdots \\
 &= f_W(f_W(f_W(\cdots f_W(f_W(h_0, x_1), x_2), \cdots, x_{t-2}), x_{t-1}), x_t)
 \end{aligned}$$

펼친 구조

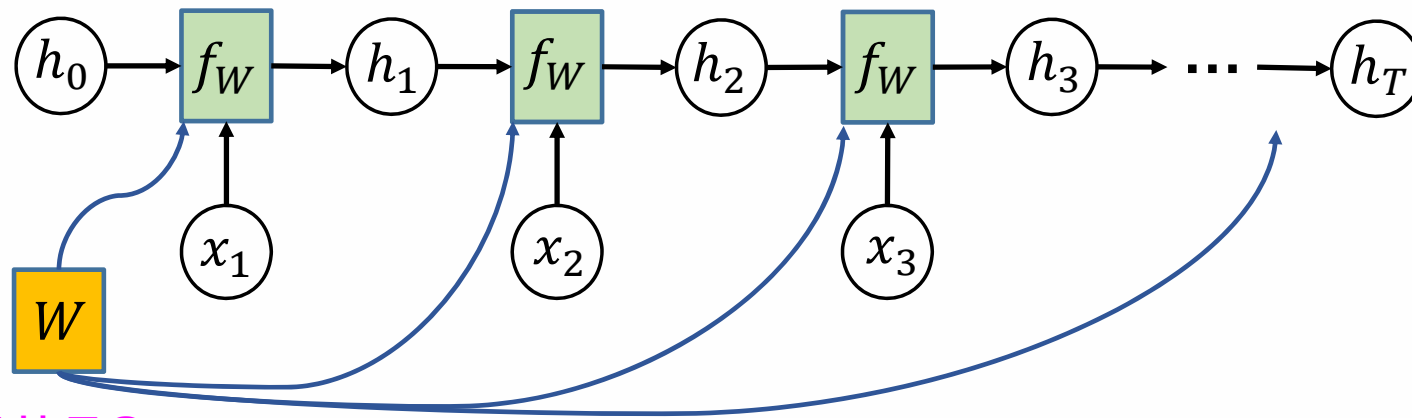
RNN의 표현 방법

○ 전개된 unfolding 구조

$$h_t = f_W(f_W(f_W(\cdots f_W(f_W(h_0, x_1), x_2), \cdots, x_{t-2}), x_{t-1}), x_t))$$




RNN의 순차적인 계산 과정



가중치 공유

RNN 셀의 구조



$$y_t = \phi_{softmax}(W_{hy}h_t + b_o)$$

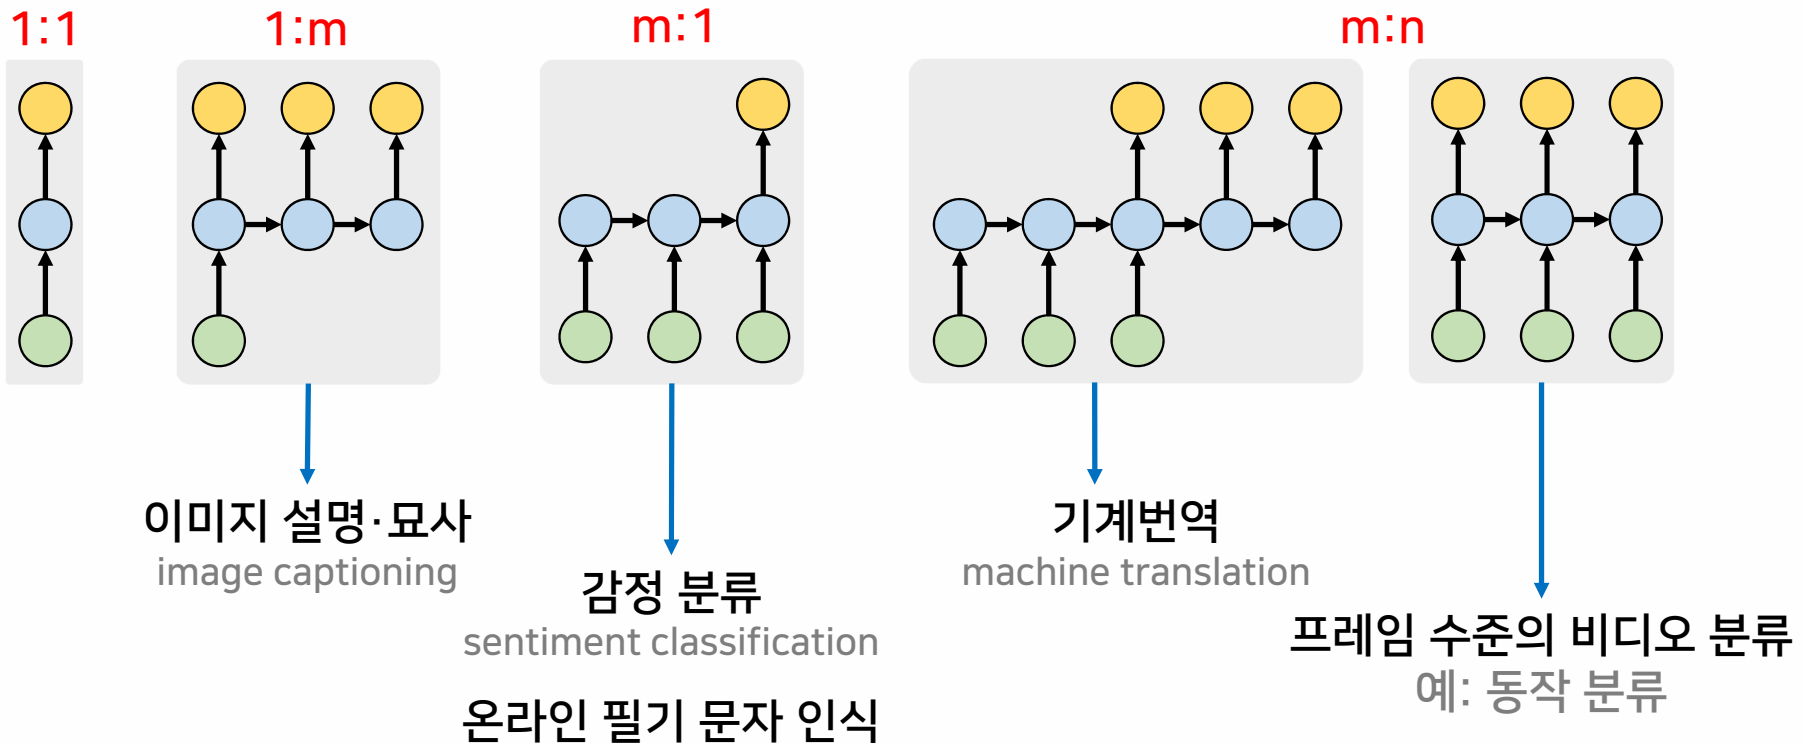
바이어스(1) 노드의 가중치

$$h_t = f_W(h_{t-1}, x_t)$$


$$= \tanh(W_{hh}h_{t-1} + W_{xh}x_t + b_h)$$

RNN 구조


○ 입출력 관계에 따른 다양한 구조와 응용



RNN 구조의 확장




다층 RNN



양방향 bidirectional RNN

RNN 학습

참고: <https://arxiv.org/pdf/1610.02583.pdf>○ 학습 데이터 집합 $D = \{(x_i, y_i)\}_{i=1, \dots, N} \rightarrow$ 지도학습

RNN 학습의 문제

시점 $i = t$ 에서 $i = 1$ 까지 역전파되는 손실함수의 기울기

$$\frac{\partial L}{\partial h_1} = \left(\frac{\partial L}{\partial y_t}\right) \left(\frac{\partial y_t}{\partial h_1}\right) = \left(\frac{\partial L}{\partial y_t}\right) \left(\frac{\partial y_t}{\partial h_t}\right) \left(\frac{\partial h_t}{\partial h_{t-1}}\right) \cdots \left(\frac{\partial h_2}{\partial h_1}\right)$$

$\mathbf{w} = W_{hh}$

$$\prod_{k=1}^{t-1} \mathbf{w} \phi'(\mathbf{w} h_{t-k}) = \mathbf{w}^{t-1} \prod_{k=1}^{t-1} \phi'(\mathbf{w} h_{t-k})$$

□ 기울기 소멸 gradient vanishing 문제

✓ 시점 1에서 t까지 길이("timestep")에 영향을 받음

□ 기울기 폭발 gradient explosion 문제

✓ 기울기가 기하급수적으로 커지는 현상


✓ 기울기 클리핑 → 기울기가 주어진 임계치보다 크면
그 값을 일정한 범위에 있도록 조정하는 해결 방법

2

LSTM과 GRU


LSTM?

○ 시간에 따른 입력 신호에 대한 민감도



장기 의존성 문제
long-term dependency

해결 방법

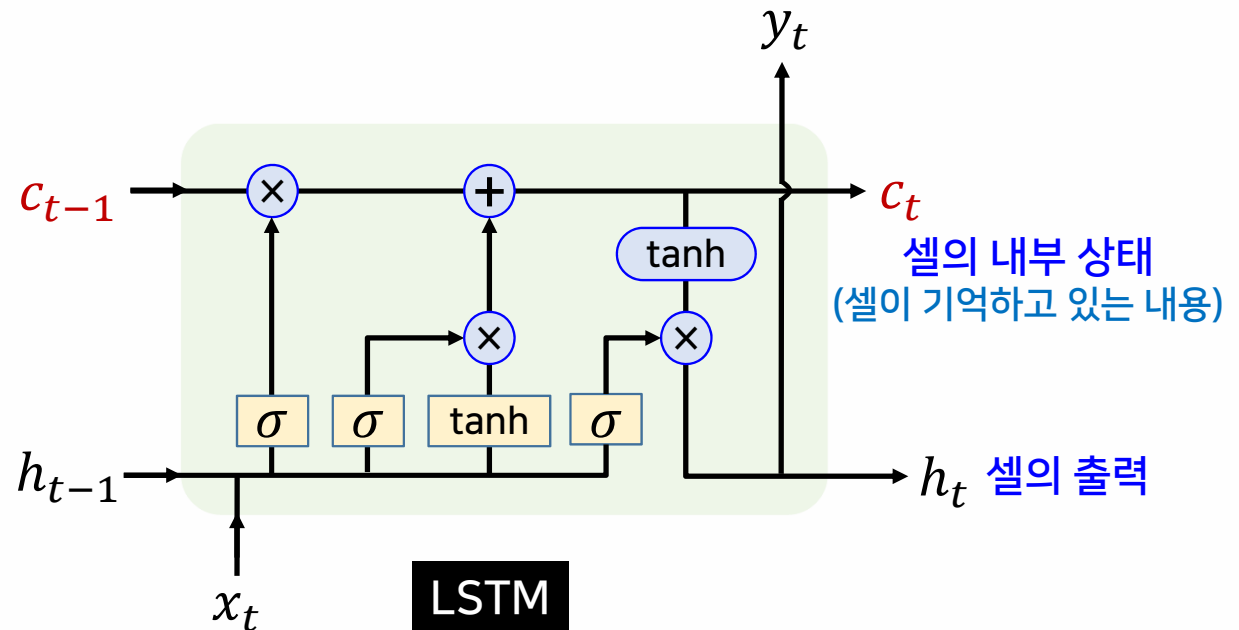



LSTM

Long Short Term Memory

LSTM 셀 구조


○ RNN 셀 vs LSTM 셀



메모리를 제어하는 게이트 → 망각 게이트, 입력 게이트

출력을 제어하는 게이트 → 출력 게이트

LSTM 셀의 기능



LSTM 셀의 기능

○ 망각 게이트 forget gate

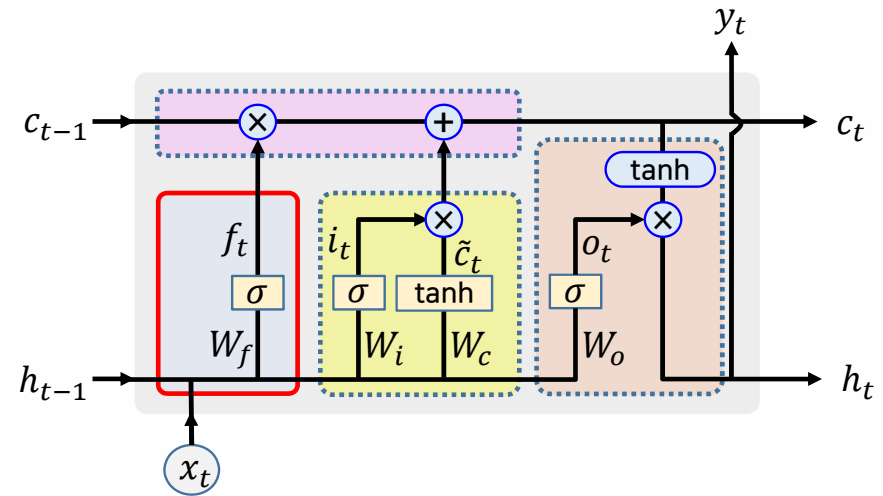
- 셀 상태 정보 c_{t-1} 를 어느 정도 잊어버릴 것인가를 결정하는 부분

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$$

시그모이드 함수 $\rightarrow [0.0, 1.0]$
 완전 망각 완전 기억

$$c_{t-1} \odot f_t$$

셀 상태 정보의 범위 $\rightarrow [0, c_{t-1}]$



LSTM 셀의 기능

○ 입력 게이트 input gate

- 셀 상태에 새로운 정보를 추가하는 정도를 조정하는 부분

\tilde{c}_t 를 셀 상태로 전달할지를 결정

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$$

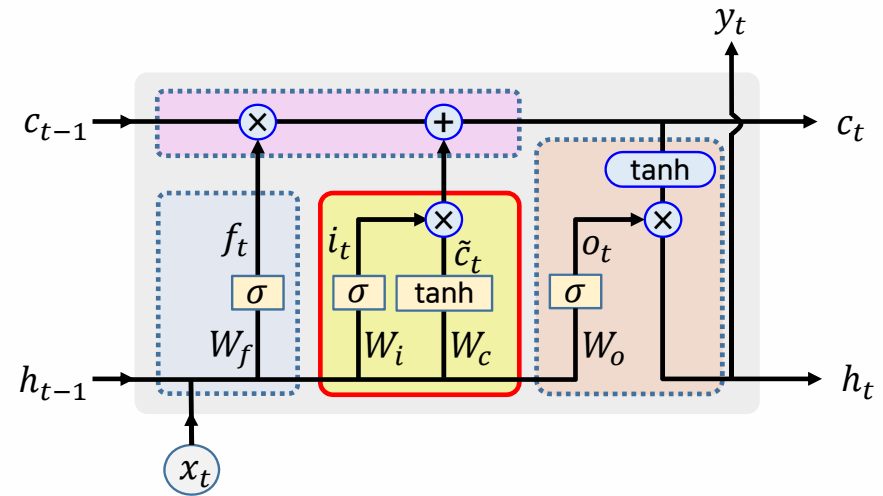
$$\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$$

셀이 출력할 후보의 값

(셀 상태에 추가될 새로운 정보)

$$\tilde{c}_t \odot i_t$$

셀 출력 후보값의 범위 $\rightarrow [0, \tilde{c}_t]$



LSTM 셀의 기능

○ 셀 상태 갱신 cell-state update

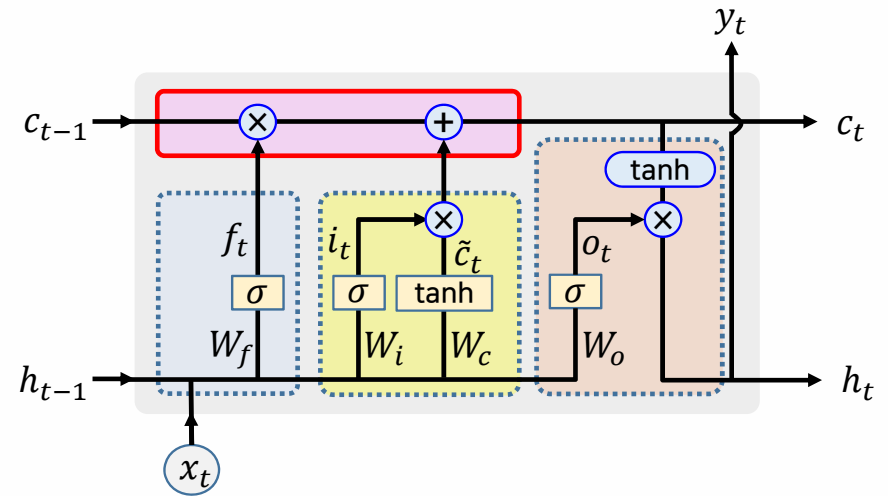
□ 새로운 셀 상태 c_t 를 갱신하는 부분

$$c_t = c_{t-1} \odot f_t + i_t \odot \tilde{c}_t$$

$[0, c_{t-1}]$

$[0, \tilde{c}_t]$

기억/망각해야 할 정보의 일부를 결정 새로운 정보 추가



LSTM 셀의 기능

○ 출력 계산

- 출력 게이트와 셀의 출력을 계산하는 부분

출력 게이트 output gate

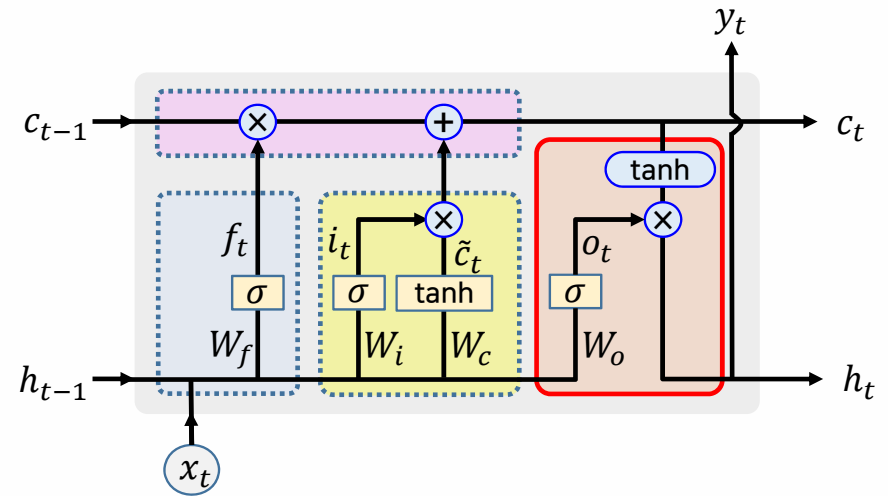
$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$$

셀의 출력 h_t

$$h_t = o_t \odot \tanh(c_t)$$

시점 t 의 출력층의 결과 y_t

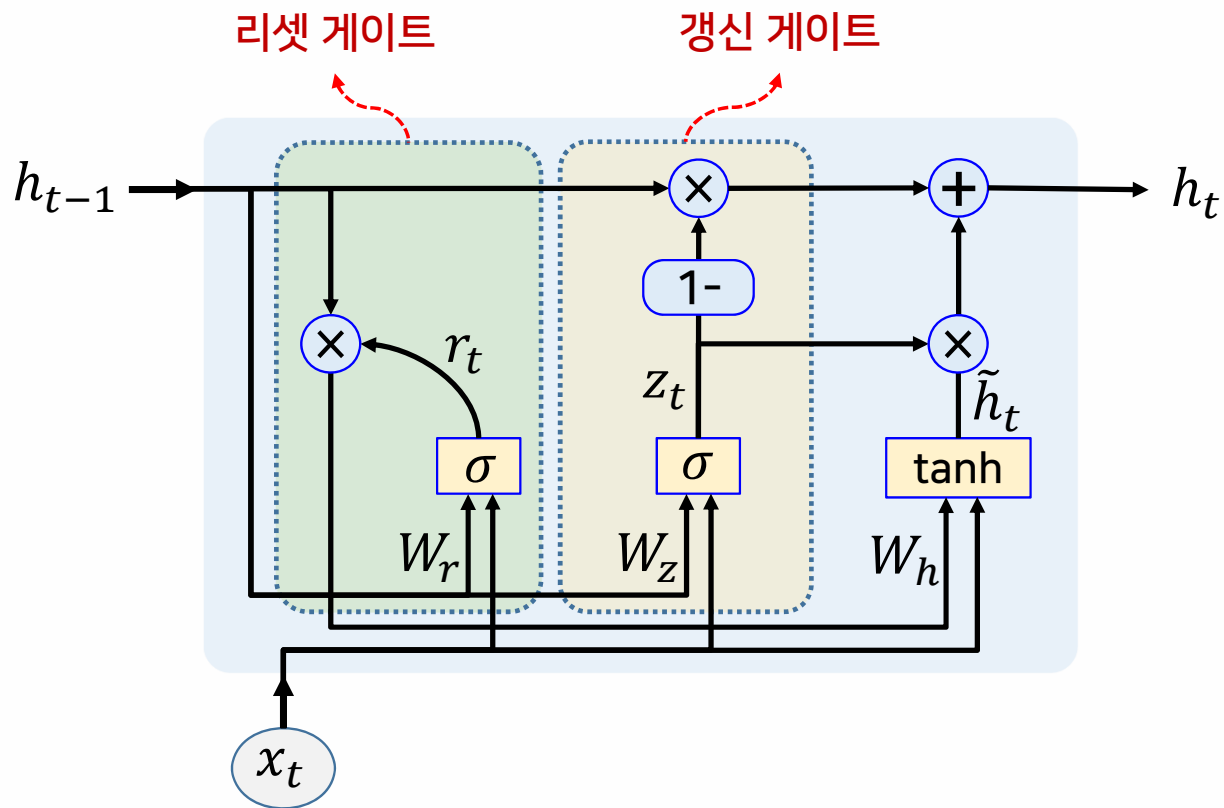
$$y_t = \phi_{softmax}(W_{hy}h_t + b_y)$$



GRU

- Gated Recurrent Unit 게이트 순환 유닛
- LSTM 셀 구조를 단순하게 개선한 것
 - 2개의 입력(h_{t-1} , x_t), 하나의 출력(h_t)
 - ✓ 셀 상태 c_t 는 없음
 - 2개의 게이트
 - ✓ 갱신 게이트 update gate $z_t \leftarrow$ 입력 게이트 + 망각 게이트
 - ✓ 리셋 게이트 reset gate r_t

GRU 셀의 구조



GRU 셀의 기능

○ 리셋 게이트

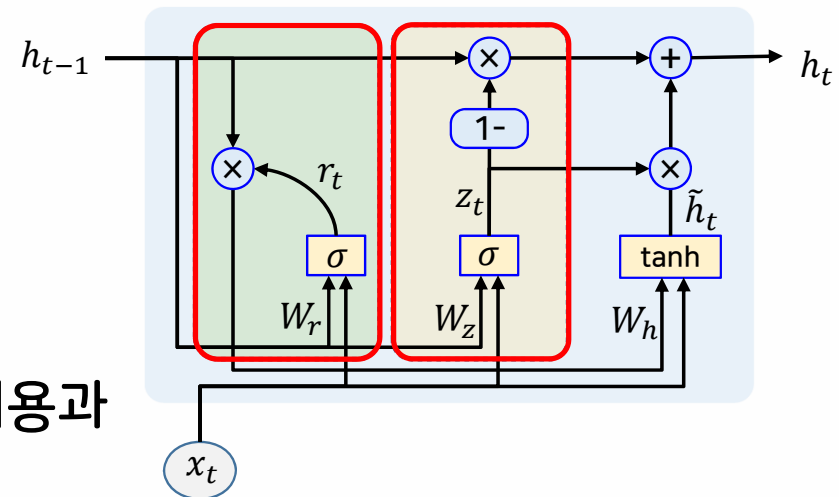
- 이전의 출력을 어느 정도 받아들이지 조정하는 부분

$$r_t = \sigma(W_r[h_{t-1}, x_t] + b_r)$$

○ 갱신 게이트

- 현 시점의 출력을 위해 받아들이 새로운 내용과 이전의 출력 내용의 비율을 조정

$$z_t = \sigma(W_z[h_{t-1}, x_t] + b_z)$$



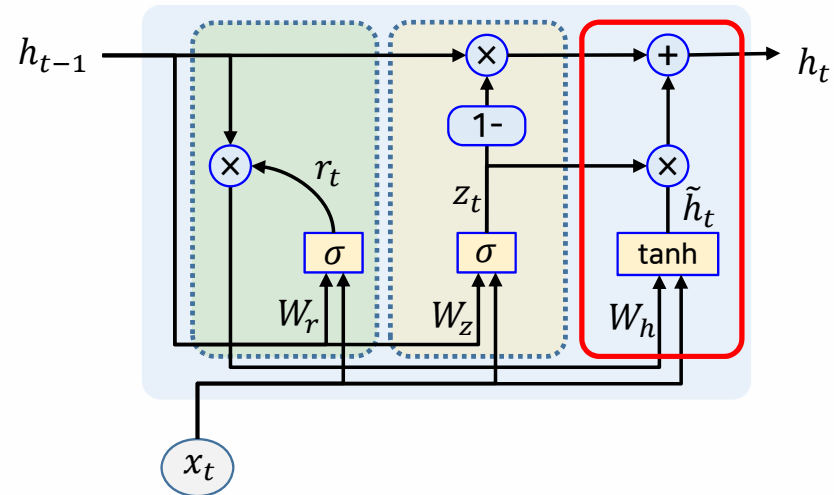
GRU 셀의 기능


○ 출력 h_t 계산추가할 새로운 내용 \tilde{h}_t

$$\tilde{h}_t = \tanh(W_h[r_t \odot h_{t-1}, x_t] + b_h)$$

셀의 최종 출력 h_t

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$





다음시간안내

제13강

딥러닝 응용 (1)-컴퓨터 비전