

베이지데이터분석 / 이재용 교수

02 강

베이지 추론






목차

➤ 베이지스 추론의 구조

➤ 점추정

➤ 구간추정






목차

> 베이지스 추론의 구조

> 점추정

> 구간추정



통계적 추론의 문제

- ▶ 모수 (θ) 자연의 법칙을 나타내는 미지의 값
- ▶ 관측치 (x) 확률분포 $f(x|\theta)$ 를 따르는 확률변수
- ▶ 목표 x 를 기초로 모수 θ 에 대한 추론을 하고자 한다.

통계적 추론의 문제

비와 우산의 예

- A는 B와 지하의 사무실을 같이 쓰고 있다. 사무실이 지하에 있기 때문에 출근한 후에 날씨의 변화를 알 수 없다. 오늘 따라 A는 사무실에 일찍 나왔다. 그런데 B가 출근할 때 비에 젖은 우산을 들고 들어왔다고 하자. A는 이를 보고 지금 비가 오고 있을 것이라고 추론할 수 있다.
- 관측 값 x 는 θ 에 따라 분포가 달라진다. 비가 오면 x 는 비에 젖은 우산을 든 B일 가능성이 높고, 비가 오지 않으면 x 는 우산을 들지 않은 B일 가능성이 높다.
- x 의 분포가 θ 에 따라 달라지기 때문에 x 는 θ 에 대한 정보를 갖고 있고 통계적 추론은 이 정보를 이용하여 θ 를 추론하는 것이다.

예 : 압정



문제

×의 확률을 알고자 한다.

예 : 압정



- ▶ 압정 10개를 던져서 7개의 \searrow 와 3개의 \perp 를 얻었다.
- ▶ \searrow 의 확률에 대해 어떤 결론을 내릴 수 있나?

▶ 모수 θ = λ 의 확률

▶ 관측치 x = 압정을 10번 던졌을 때 λ 가 나온 횟수

▶ 문제 $x = 7$ 를 관측했을 때 θ 에 관한 추론은?

➤ 베이지스 추론은 다음의 세 가지 요소로 이루어져 있다.

- **사전분포**: θ 의 분포로 자료를 보기 전의 분석자의 θ 에 관한 정보 (혹은 불확실성)를 나타낸다.
 $\pi(\theta)$ 로 나타낸다.
- **확률모형**: $x|\theta \sim f(x|\theta)$.
- **사후분포**: 자료가 주어졌을 때 θ 의 확률분포로 자료를 본 후의 분석자의 θ 에 관한 정보를 나타낸다.
 $\pi(\theta|x)$ 로 나타낸다.

베이즈 법칙: 사후분포의 계산방법

베이즈 법칙 혹은 베이즈 정리는 사후분포를 계산하는 수학적 방법이다.

$$\pi(\theta|x) \propto \pi(\theta)f(x|\theta)$$

혹은

$$\text{사후분포} \propto \text{사전분포} \times \text{가능도}.$$

압정의 예: 사후분포의 계산

- ▶ 사전분포: $\theta \sim U(0, 1)$.

자료 x 를 보기 전에, 모든 θ 값이 동일한 가능성을 갖고 있다면, 즉 모든 $\theta_1 \neq \theta_2$ 에 대하여 $\pi(\theta_1) = \pi(\theta_2)$ 라면 $\theta \sim U(0, 1)$.

- ▶ 가능도: $x|\theta \sim \text{Bin}(n, \theta)$.

- ▶ 사후분포

$$\begin{aligned}\pi(\theta|x) &\propto \pi(\theta) \times f(x|\theta) \\ &= 1 \times \binom{n}{x} \theta^x (1 - \theta)^{n-x} \\ &\propto \theta^x (1 - \theta)^{n-x}, 0 < \theta < 1. \\ \theta|x &\sim \text{Beta}(x + 1, n - x + 1).\end{aligned}$$

- ▶ 압정의 예에서는,

$$\theta|x = 7 \sim \text{Beta}(8, 4).$$

- ▶ **균등분포 (uniform distribution)**: 연속형 확률변수 X 가 밀도함수

$$f(x) = \frac{1}{b-a} I(a \leq x \leq b)$$

를 따르면, $X \sim U(a, b)$, $a < b$ 라 쓴다.

- ▶ **이항분포 (binomial distribution)**:

이산형 확률변수 X 가 밀도함수

$$P(X = x) = f(x) = \binom{n}{x} p^x (1-p)^{n-x}$$

를 따르면, $X \sim \text{Bin}(n, p)$ 라 쓴다.

- ▶ 베타분포 (beta distribution): 연속형 확률변수 X 가 밀도함수


$$f(x) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, 0 < x, 1$$

를 따르면 $X \sim \text{Beta}(\alpha, \beta), \alpha, \beta > 0$ 라 쓴다.

- ▶ 감마함수 (gamma function):


$$\Gamma(\alpha) := \int_0^{\infty} x^{\alpha-1} e^{-x} dx, \alpha > 0.$$

사후확률밀도함수



베이즈 통계의 장점

- ▶ 새로운 자료가 관측되었을 때, 정보를 업데이트 하는 것이 자연스럽다. 과거의 사후분포가, 현재의 사전분포가 된다.



- ▶ (전문가 의견의 이용) 과거의 경험으로부터 강한 사전 정보 혹은 의견이 있을 때, 이를 추론에 이용할 수 있다.
- ▶ (계층모형) 비슷한 값들을 동시에 추정해야 할 때 정보를 종합해서 추론하는데 장점이 있다.
- ▶ 구간 추정과 가설 검정의 결과의 해석이 자연스럽다.
- ▶ 추론을 할 때, 대표본이론을 이용한 근사를 이용하지 않아도 된다. 베イズ추론은 유한 표본에서도 정확한 추론분포를 이용한다.
- ▶ 빈도론 추론 방법이 베イズ 방법의 일종이 되는 경우가 많다.

베이즈 통계의 적용 예들



Alan Turing이
2차 세계대전에서
독일군의
암호를 풀 때
베이즈 통계를
사용하였다.

미국의전 연방준비제도
이사회 회장이었던
Alan Greenspan은
금융정책 결정과정에
베이즈 결정론을
이용한다고 말했다.



MS 오피스의
길잡이도
베이즈 통계를
이용하였다.
빌 게이트는 베이즈
주의자라고 알려져 있다.

이항모형

▶ 사전분포: $\theta \sim \text{Beta}(\alpha, \beta), \alpha, \beta > 0$

▶ 모형: $x|\theta \sim \text{Bin}(n, \theta)$

▶ 사후분포:

$$\theta|x \sim \text{Beta}(\alpha + x, \beta + n - x), x = 0, 1, \dots, n.$$

- ▶ 베이즈 추정량은 사전분포의 평균과 최대가능도 추정량의 가중평균이다.

$$\hat{\theta}^B = \mathbb{E}(\theta|x) = \frac{\alpha+\beta}{\alpha+\beta+n} \frac{\alpha}{\alpha+\beta} + \frac{n}{\alpha+\beta+n} \frac{x}{n}.$$

$$\mathbb{E}(\theta) = \frac{\alpha}{\alpha+\beta} \text{ 이고 } \hat{\theta}^{MLE} = \frac{x}{n} \text{ 이다.}$$

- ▶ 표본의 크기가 커지면서 사전분포는 사라진다. 즉, 자료가 사전분포를 압도한다.

$$\lim_{n \rightarrow \infty} \hat{\theta}^B = \hat{\theta}^{MLE}.$$

- ▶ 사전분포 파라미터의 결정: $\alpha + \beta$ 를 사전표본의 크기로 해석한다.

균등사전분포와 불충분근거의 원칙

θ 에 대한 사전분포로

$$\theta \sim U(0, 1)$$

를 많이 사용한다.

- 라플라스는 균등분포가 완전한 무지를 표현한다고 생각했다.
- 불충분근거의 원칙이란 근거가 없는 경우 두 개의 다른 사건은 동일한 사전 확률을 갖는다는 원칙이다.
- 베이즈는 균등분포를 사전분포로 쓸 때, x 의 주변분포가 이산균등분포가 되는 것을 보고 $U(0, 1)$ 을 사전분포로 써야 하는 이유라고 생각했다.
- $\theta \sim U(0, 1) = \text{Beta}(1, 1)$, $x|\theta \sim \text{Bin}(n, \theta)$ 이면, $\theta|x \sim \text{Beta}(x + 1, n - x + 1)$ 이다.

정규모형 : 평균을 모르고 분산은 아는 경우

- ▶ (모형) σ^2 은 아는 값이고, θ 에 대해 추론하고자 한다.

$$X_1, \dots, X_n \mid \theta \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2)$$

- ▶ (사전분포) $\theta \sim N(\mu, \tau^2)$
- ▶ (사후분포)

$$\theta \mid x \sim N\left(\frac{\frac{1}{\tau^2}\mu + \frac{n}{\sigma^2}\bar{X}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}\right).$$

여기서 $x = (x_1, \dots, x_n)$ 이다.

정규모형 : 평균을 모르고 분산은 아는 경우

- ▶ 베이즈 추정량은 사전분포의 평균과 최대가능도 추정량의 가중 평균이다.

$$\hat{\theta}^B = \frac{\frac{1}{\tau^2}\mu + \frac{n}{\sigma^2}\bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} = \frac{\frac{1}{\tau^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}\mu + \frac{\frac{n}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}\bar{x}.$$

여기서 μ 는 사전분포의 평균이고 \bar{x} 는 $\hat{\theta}^{MLE}$ 이다.

- ▶ 관측치의 개수가 커지면서, 자료가 사전분포를 압도한다. 즉

$$\lim_{n \rightarrow \infty} \hat{\theta}^B = \hat{\theta}^{MLE}.$$

- ▶ 사전분포 모수의 결정: $\tau^2 = \sigma^2/k$ 라 놓을 때, k 를 사전표본의 개수라 한다.
- ▶ 점근적으로 사후분포와 최대가능도 추정량의 분포가 동일하다.

$\theta \in \mathbb{R}$ 에 대한 균등분포

- ▶ (균등사전분포일 때의 사후분포)

$$\theta \sim \pi(\theta) = 1, \forall \theta \in \mathbb{R}$$

균등분포 $\pi(\theta)$ 는 엄밀한 의미에서 확률분포가 아니다.

그럼에도 불구하고, 사후분포를 계산해보면

$$\theta|x \sim N\left(\bar{x}, \frac{\sigma^2}{n}\right)$$

으로, 자료가 사전분포를 압도한 사후분포의 값으로 합리적이다.

- ▶ 균등사전분포일 때의 사후분포는 어떤 사전분포의 사후분포들의 극한이다.

$$\lim_{\tau^2 \rightarrow \infty} [\theta|x]_{\pi} = N(\mu, \tau^2) = [\theta|x]_{\pi(\theta)} = 1.$$

감마분포로 정의되는 분포들

▶ (감마분포) $X \sim Ga(\alpha, \beta), \alpha, \beta > 0$.

- 밀도함수: $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, x > 0$.
- $\mathbb{E}X = \frac{\alpha}{\beta}, \mathbb{V}ar(X) = \frac{\alpha}{\beta^2}$.

▶ (카이제곱분포) $X \sim \chi^2(\nu) = Ga\left(\frac{\nu}{2}, \frac{1}{2}\right)$.

- 밀도함수:

$$f(x) = \frac{\left(\frac{1}{2}\right)^{\frac{\nu}{2}}}{\Gamma\left(\frac{\nu}{2}\right)} x^{\frac{\nu}{2}-1} e^{-\frac{1}{2}x}, x > 0.$$

- $\mathbb{E}X = \nu, \mathbb{V}ar(X) = 2\nu$.

감마분포로 정의되는 분포들

▶ (척도 카이제곱분포) $X \sim \chi^2(\nu, \lambda) = Ga(\frac{\nu}{2}, \frac{\nu}{2} \lambda)$.

• 밀도함수:

$$f(x) = \frac{\left(\frac{\nu\lambda}{2}\right)^{\frac{\nu}{2}}}{\Gamma\left(\frac{\nu}{2}\right)} x^{\frac{\nu}{2}-1} e^{-\frac{\nu\lambda}{2}x}, x > 0.$$

• $\mathbb{E}X = \frac{1}{\lambda}, \text{Var}(X) = \frac{2}{\nu\lambda^2}.$

▶ (역감마분포) $X \sim Inv - Ga(\alpha, \beta) \iff 1/X \sim Ga(\alpha, \beta), \alpha, \beta > 0.$

• 밀도함수: $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} \left(\frac{1}{x}\right)^{\alpha+1} e^{-\beta/x}, x > 0$

• $\mathbb{E}X = \frac{\beta}{\alpha-1}, \alpha > 1$

$$\text{Var}(X) = \frac{\beta^2}{(\alpha-1)^2(\alpha-2)}, \alpha > 2.$$

감마분포로 정의되는 분포들

▶ (역카이제곱분포) $X \sim \text{Inv-}\chi^2(\nu) = \text{Inv-Ga}(\frac{\nu}{2}, \frac{1}{2})$.

- 밀도함수: $f(x) = \frac{\left(\frac{1}{2}\right)^{\frac{\nu}{2}}}{\Gamma(\frac{\nu}{2})} \left(\frac{1}{x}\right)^{\frac{\nu}{2}+1} e^{-\frac{1}{2x}}, x > 0$.

- $\mathbb{E}X = \frac{1}{\nu-2}, \nu > 2$

$$\text{Var}(X) = \frac{2}{(\nu-2)^2(\nu-4)}, \nu > 4.$$

▶ (역척도 카이제곱분포) $X \sim \text{Inv-}\chi^2(\nu, \lambda) = \text{Inv-Ga}(\frac{\nu}{2}, \frac{\nu}{2}\lambda)$.

- 밀도함수: $f(x) = \frac{\left(\frac{\nu\lambda}{2}\right)^{\frac{\nu}{2}}}{\Gamma(\frac{\nu}{2})} \left(\frac{1}{x}\right)^{\frac{\nu}{2}+1} e^{-\frac{\nu\lambda}{2x}}, x > 0$.

- $\mathbb{E}X = \frac{1}{\nu-2}\lambda, \nu > 2$

$$\text{Var}(X) = \frac{2\nu^2\lambda^2}{(\nu-2)^2(\nu-4)}, \nu > 4.$$

정규모형 : 평균을 알고 분산에 대해 추론하는 경우

모형

θ 는 아는 값이고, $\sigma^2 > 0$ 에 대해 추론하고자 한다.

$$x_1, \dots, x_n \mid \sigma^2 \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2)$$

사전분포

$$\begin{aligned} \sigma^2 &\sim \text{Inv} - \mathcal{X}^2(\nu_0, \sigma_0^2) \\ \Leftrightarrow \tau^2 = \frac{1}{\sigma^2} &\sim \mathcal{X}^2(\nu_0, \sigma_0^2) = \text{Ga}\left(\frac{\nu_0}{2}, \frac{\nu_0 \sigma_0^2}{2}\right) \end{aligned}$$

사후분포

$$\begin{aligned} \tau^2 \mid x &\sim \mathcal{X}^2\left(\nu_n = \nu_0 + n, \sigma_n^2 = \frac{\nu_0 \sigma_0^2 + n s^2}{\nu + n}\right) \\ \text{혹은 } \sigma^2 \mid x &\sim \text{Inv} - \mathcal{X}^2(\nu_n, \sigma_n^2) \\ \text{여기서 } s^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \theta)^2. \end{aligned}$$




목차

> 베이지스 추론의 구조

> 점추정

> 구간추정



추정: 세 가지 사후분포의 한 점 요약

사후분포의 평균

$$\hat{\theta}^M := \mathbb{E}(\theta|x) = \int \theta \pi(\theta|x) d\theta .$$

최대사후밀도추정량

$$\hat{\theta}^{MAP} := \operatorname{argmax}_{\theta} \pi(\theta|x)$$

- 사후밀도함수의 모드 혹은 최대값
- MAP (maximum a posteriori) 추정량이라고도 한다.
- 사전분포가 균등분포일 때 최대가능도 추정량

사후분포의 중앙값

$$\hat{\theta}^{med} := \operatorname{med}^{\pi(\theta|x)}(\theta) .$$

➤ (정의)

$$\hat{\theta}^{MLE} := \operatorname{argmax}_{\theta} L(\theta).$$

여기서 $L(\theta)$ 는 모형의 가능도로 *iid* 모형의 경우

$$L(\theta) = \prod_{i=1}^n f(x_i|\theta)$$

이다.

- 최대가능도추정량(MLE, maximum likelihood estimator)는 가능도를 최대로 하는 θ 값이다.

추정의 두 가지 예

이항모형

▶ (사전분포) $\theta \sim \text{Beta}(\alpha, \beta), \alpha, \beta > 0$

▶ (모형) $x|\theta \sim \text{Bin}(n, \theta)$

▶ (사후분포)

$$\theta|x \sim \text{Beta}(\alpha + x, \beta + n - x), x = 0, 1, \dots, n.$$

▶ (문제) 세 가지 추정량을 구해보자.

추정의 두 가지 예

정규모형

- ▶ (모형) σ^2 은 아는 값이고, θ 는 모르는 값이다.

$$x_1, \dots, X_n \mid \theta \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2)$$

- ▶ (사전분포) $\theta \sim N(\mu, \tau^2)$

- ▶ (사후분포)

$$\theta \mid x \sim N \left(\frac{\frac{1}{\tau^2} \mu + \frac{n}{\sigma^2} \bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} \right).$$

여기서 $x = (x_1, \dots, x_n)$ 이다.

- ▶ (문제) 세 가지 추정량을 구해보자.

추정오차(estimation error)

- ▶ 추정치 δ 의 사후분포의 표준편차와 분산을 δ 의 추정오차로 쓴다.
- ▶ 사후분포의 산포에 관한 측도로 사후분포의 분산과 표준편차를 쓴다.

예

사후분포가

$$\theta|x \sim N \left(\frac{\frac{1}{\tau^2}\mu + \frac{n}{\sigma^2}\bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \left(\frac{1}{\tau^2} + \frac{n}{\sigma^2} \right)^{-1} \right)$$

와 같이 주어질 때, 사후분포의 분산과 표준편차를 구해보자.
또한 추정량 $\delta(x) = \bar{x}$ 의 사후분산을 구해보자




목차

> 베이지스 추론의 구조

> 점추정

> 구간추정



신용집합(credible set)

100(1 - α)% 신용집합의 정의

집합 $C \subseteq \Theta$ 이 $\pi(C|x) \geq 1 - \alpha$ 를 만족하면, C 를 θ 의 100(1 - α)%, $0 \leq \alpha \leq 1$ 신용집합이라고 한다.

최고사후밀도(Highest posterior density, HPD) 신용집합

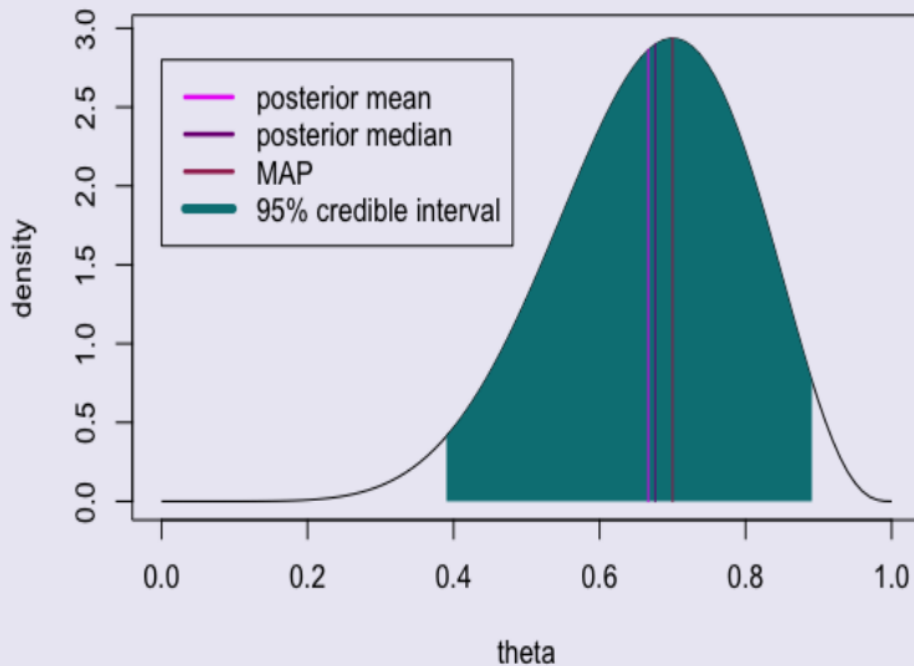
θ 의 100(1 - α)% 최고사후밀도 신용집합 $C \subseteq \Theta$ 는 $C = \{\theta \in \Theta : \pi(\theta|x) \geq k\}$ 와 같이 정의된다. 여기서 k 는 $P(C|x) \geq 1 - \alpha$ 가 되도록 정해진다.

동일꼬리 신용집합(equal tail credible set)

θ 의 100(1 - α)% 동일꼬리 신용집합은 $[A, B]$ 와 같이 정의되고, A, B 는 $\pi(\theta \leq A|x) = \frac{\alpha}{2}$ 와 $\pi(\theta \geq B|x) = \frac{\alpha}{2}$ 을 만족한다.

정규모형의 예

압정의 예



➤ θ 의 95% 신용구간은
(0.390, 0.891)

이다.

구간추정의 해석

▶ 빈도론자의 95% 신뢰구간 해석

동일한 실험을 무한히 반복해서 동일한 방법으로 신뢰구간들을 계산하면 이 중 95%의 신뢰구간이 모수 θ 를 포함한다.

이 해석은 당장 우리 손 안에 있는 신뢰구간에 대해 아무런 말도 하지 못한다.

▶ 베이즈주의자의 95% 신용구간에 대한 해석

주어진 자료에 대해, 계산된 신용구간이 모수를 포함할 확률이 95%이다.

확률의 의미

- ▶ 빈도론적 해석.

빈도론적 해석은 무한히 반복 가능한 실험에 대해서만 적용 가능하다. 사건 A의 확률은

$$\frac{\text{사건 A의 빈도}}{\text{실험의 반복수}}.$$

- ▶ 주관적 확률의 해석.

개인적 믿음의 정도

- ▶ 베이즈주의자들은 주관적 확률의 해석을 믿고 모든 불확실성은 확률로 표현 가능하다고 믿는다.

베이지주의자들이 믿는 것들

- 미지의 모수에 대한 추론은 자료(와 사전분포)에 대해서만 의존해야 하고 관측할 수도 있었던 값들에 의존하면 안된다.

놀랍게도 빈도론적 추론에서는 관측될 수도 있으리라 믿어지는 값들이지만 정작 관측되지는 않은 값들에 의해 추론이 의존한다.

- 모든 불확실성은 확률로 표현 가능하다.

따라서 모수에 대한 불확실성은 자료가 관측되었건 안되었건 확률분포로 표현 가능하다.

신용집합(credible set): 정규모형의 예

집합 $C \subseteq \Theta$ 이 $\pi(C|x) \geq 1 - \alpha$ 를 만족하면, C 를 θ 의 $100(1 - \alpha)\%$, $0 \leq \alpha \leq 1$ **신용집합**이라고 한다.

θ 의 $100(1 - \alpha)\%$ **최고사후밀도 신용집합** $C \subseteq \Theta$ 는 $C = \{\theta \in \Theta : \pi(\theta|x) \geq k\}$ 와 같이 정의된다. 여기서 k 는 $P(C|x) \geq 1 - \alpha$ 가 되도록 정해진다.

θ 의 $100(1 - \alpha)\%$ **동일꼬리 신용집합**은 $[A, B]$ 와 같이 정의되고, A, B 는 $\pi(\theta \leq A|x) = \frac{\alpha}{2}$ 와 $\pi(\theta \geq B|x) = \frac{\alpha}{2}$ 을 만족한다

신용집합(credible set): 정규모형의 예

- (모형) σ^2 은 아는 값이고, θ 는 모르는 값이다.

$$x_1, \dots, X_n \mid \theta \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2)$$

- (사전분포) $\theta \sim N(\mu, \tau^2)$

- (사후분포)

$$\theta \mid x \sim N\left(\frac{\frac{1}{\tau^2}\mu + \frac{n}{\sigma^2}\bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}\right).$$

여기서 $x = (x_1, \dots, x_n)$ 이다.

- (문제) θ 의 95% 신용구간을 구하자.

다음시간

03 강 _____

R의 소개와 실습

