

베이지데이터분석 / 이재용 교수

09강


깁스추출법





목차


- 고차원 확률변수 생성의 문제점
- 깃스추출법
- MCMC 수렴진단
- 깃스추출법의 변형





목차

- 고차원 확률변수 생성의 문제점
- 깃스추출법
- MCMC 수렴진단
- 깃스추출법의 변형



합격불합격 방법으로 1차원 정규 확률변수의 생성

▶ (목적)

$$y \sim c_1 f(x) = c_1 e^{-y^2/2}, c_1 = \frac{1}{\sqrt{2\pi}}$$

▶ (제안 밀도함수)

$$x \sim c_2 g(x) = c_1 \frac{1}{1+x^2}, c_2 = \frac{1}{\pi}$$

$$\sup_x \frac{f(x)}{g(x)} \leq M, M = 2/\sqrt{e}.$$

▶ (합격확률)

$$\mathbb{E}\alpha(x) \approx 0.66$$

합격불합격 방법으로 k - 차원 정규 확률변수의 생성

▶ (목적)

$$y \sim c_1 f(y) = c_1 e^{-\frac{1}{2} \sum_{i=1}^k y_i^2}, c_1 = \frac{1}{(2\pi)^{k/2}}$$

▶ (제안 밀도함수)

$$x \sim c_2 g(x) = c_2 \prod_{i=1}^k \frac{1}{1 + x_i^2}, c_2 = \frac{1}{\pi^k}$$
$$\sup_x \frac{f(x)}{g(x)} \leq M = \left(\frac{2}{\sqrt{e}} \right)^k$$

합격불합격 방법으로 k - 차원 정규 확률변수의 생성

▶ (합격확률)

$$\begin{aligned} & \mathbb{P}(u \leq \frac{1}{M} \prod_{i=1}^k ((1 + x_i^2) e^{-x_i^2/2})) \\ &= \mathbb{E} \mathbb{P}(u \leq \frac{1}{M} \prod_{i=1}^k ((1 + x_i^2) e^{-x_i^2/2}) | x) \\ &= \mathbb{E} (\frac{1}{M} \prod_{i=1}^k ((1 + x_i^2) e^{-x_i^2/2})) \\ &= \left(\frac{\sqrt{e}}{2}\right)^k \prod_{i=1}^k \int (1 + x_i^2) \cdot e^{-x_i^2/2} \cdot \frac{1}{\pi} \cdot \frac{1}{1 + x_i^2} dx_i \end{aligned}$$


$$\begin{aligned} &= \left(\frac{\sqrt{e}}{2\pi}\right)^k \prod_{i=1}^k \int e^{-x_i^2/2} dx_i \\ &= \left(\sqrt{\frac{e}{2\pi}}\right)^k \\ &k = 10 \text{ 일 때,} \\ &0.01568; k = 100 \text{ 일 때,} \\ &9.003 \times 10^{-19}. \end{aligned}$$

차원이 커질수록 확률을 생성하기가 현실적으로 어려워진다.



목차

- ▶ 고차원 확률변수 생성의 문제점
- ▶ **깁스추출법**
- ▶ MCMC 수렴진단
- ▶ 깁스추출법의 변형



▶ 마르코프 체인(Markov chain)

: t 시점의 값이 직전 값에만 의존하는 확률변수들의 수열.

$(\theta^{(0)}, \theta^{(1)}, \theta^{(2)}, \dots)$ 가 확률변수들의 열일 때,

$$[\theta^{(t)} | \theta^{(t-1)}, \theta^{(t-2)}, \dots, \theta^{(0)}] = [\theta^{(t)} | \theta^{(t-1)}], \forall t \geq 0$$

를 만족하면 $(\theta^{(0)}, \theta^{(1)}, \theta^{(2)}, \dots)$ 를 마르코프 체인이라 한다.

$[\theta^{(0)}]$ 는 확률변수 $\theta^{(0)}$ 의 분포를 의미한다.

- ▶ 마르코프 체인의 커널(Kernel): 직전 값이 주어졌을 때 현재 값의 분포. $[\theta^{(t)}|\theta^{(t-1)}]$ 혹은 $K(\theta^{(t-1)}, \theta^{(t)})$ 로 표현한다.
- ▶ 마르코프 체인 몬테 카를로(Markov chain Monte Carlo, MCMC)
: 마르코프 체인을 이용한 적분의 근사법, 즉 몬테 카를로 방법.
- ▶ 마르코프 체인의 정상분포(stationary distribution)
: 마르코프 체인이 오랜 시간 생성될 때 수렴하는 분포. 즉 t 가 매우 클 때, $\theta^{(t)}$ 의 분포.

- ▶ 깁스추출법(Gibbs sampling)은 다차원 확률변수를 추출하는 방법이다.
- ▶ $\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(m)}$ 이 사후분포 $\pi(\theta|x)$ 를 추론하기 위해 깁스추출법으로 추출한 사후표본일 때 다음이 성립한다.
 - 사후표본 ($\theta^{(t)}$)은 서로 독립인 랜덤표본이 아니라 마르코프 체인이 된다.
 - 마르코프 체인 ($\theta^{(t)}$)의 정상분포(혹은 불변분포)는 사후분포 $\pi(\theta|x)$ 가 된다.
 - 사후표본의 표본평균은 사후분포의 기대값을 근사하고, 사후표본의 표본분위수는 사후분포의 분위수를 근사한다.

김스 알고리즘

$(\theta_1, \theta_2, \theta_3)$ 의 밀도함수가 $\pi(\theta_1, \theta_2, \theta_3)$ 이고,
 θ_{-i} 는 θ 에서 i 번째 원소를 제외한 나머지라고 하자.

단계 1. 초기값 $(\theta_1^{(0)}, \theta_2^{(0)}, \theta_3^{(0)})$ 을 선정한다.

단계 2. $t = 1, 2, 3, \dots$ 에 대하여, $\theta^{(t)}$ 의 각 원소를
조건부 분포로 부터 추출한다. 즉,

- $\theta_1^{(t)} \sim \pi_{\theta_1}(\cdot | \theta_2^{(t-1)}, \theta_3^{(t-1)})$ 을 추출한다.
- $\theta_2^{(t)} \sim \pi_{\theta_2}(\cdot | \theta_1^{(t)}, \theta_3^{(t-1)})$ 을 추출한다.
- $\theta_3^{(t)} \sim \pi_{\theta_3}(\cdot | \theta_1^{(t)}, \theta_2^{(t)})$ 을 추출한다.

단계 3. $\theta^{(1)}, \theta^{(2)}, \dots$ 는
 $\pi(\theta_1, \theta_2, \theta_3)$ 를
정상분포로 갖는
마르코프 체인이 된다.

깁스추출법의 예: 이변량 정규분포

목표

$$\pi = N \left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \right)$$

를 정상분포로 갖는 깁스추출표본을 구하자.

마르코프체인의 사용

마르코프체인의 사용

$(\theta_1^{(t)}, \theta_2^{(t)}), t \geq 0$ 를 이용해 정규분포의 적률과 분위수를 구한다.

$$\int h(\theta_1, \theta_2) \widehat{\pi}(\theta_1, \theta_2) d\theta_1 d\theta_2 = \frac{1}{n} \sum_{t=1}^n h(\theta_1^{(t)}, \theta_2^{(t)})$$

$$\text{i.e., } P(\theta_1 \geq 0, \theta_2 \geq 0) = \frac{1}{n} \sum_{t=1}^n I(\theta_1^{(t)} \geq 0, \theta_2^{(t)} \geq 0).$$

알고리즘

단계 1. 초기값 $(\theta_1^{(0)}, \theta_2^{(0)})$ 을 선정한다.

단계 2. $t = 1, 2, 3, \dots$ 에 대하여, $\theta^{(t)}$ 의 각 원소를 조건부 분포로부터 추출한다. 즉,

(i) $\theta_1^{(t)} \sim$

$$N(\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (\theta_2^{(t-1)} - \mu_2), \sigma_1^2 (1 - \rho^2))$$

를 발생한다.



(ii) $\theta_2^{(t)} \sim$

$$N(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (\theta_1^{(t)} - \mu_1), \sigma_2^2 (1 - \rho^2))$$

를 발생한다.

단계 3. $\theta^{(1)}, \theta^{(2)}, \dots$ 는 이변량 정규분포를 정상분포로 갖는 마르코프 체인이 된다.

이변량 정규분포 깃스표본의 궤적




$\rho = 0$ 일 때와 $\rho = 0.99$ 일 때 초기 깃스 표본의 궤적의 그림이다.



목차

- › 고차원 확률변수 생성의 문제점
- › 깃스추출법
- › MCMC 수렴진단
- › 깃스추출법의 변형



마르코프 체인 수렴의 문제


- 마르코프 체인은 서로 독립인 표본과 달리 정상분포로 수렴을 하는데 시간이 걸릴 수 있다.
- 마르코프 체인이 수렴했는지 판단하는 것을 수렴 진단이라 한다.

실제적인 방법들


- 번인(Burn-in): 엠씨엠씨 표본의 앞부분을 버리는 것을 말한다.
- 가늘게하기(thinning): 엠씨엠씨 표본의 자기상관계수가 높을 때, 모든 표본을 다 사용하지 않고 r 번째 표본만 따로 추출해서 사용하는 것을 말한다. 가늘게하기로 컴퓨터의 메모리를 절약할 수 있다.

그림을 이용한 진단


- 시계열 그림



- 자기상관계수 그림



시계열그림과 자기상관계수 그림을 이용한 수렴진단




맨 위 행의 그림은 마르코프체인에 문제가 없어 보인다. 두 번째 행은 자기 상관계수가 너무 크다. 이 때는 가늘게하기를 할 필요가 있다. 세 번째 행은 마르코프체인이 초기값에 의존한다. 번인을 할 필요가 있다.



목차

- › 고차원 확률변수 생성의 문제점
- › 깃스추출법
- › MCMC 수렴진단
- › 깃스추출법의 변형



목표 사후 밀도 함수의 형태

$$\pi(\theta) \propto \prod_{i=1}^k f_i(\theta), f_i(\theta) \geq 0 (\forall i)$$

잠재변수의 추가

$f_i(\theta)$ 를 적분의 형태로 써보면

$$\pi(\theta) \propto \prod_{i=1}^k f_i(\theta), = \prod_{i=1}^k \int I(0 \leq w_i \leq f_i(\theta)) dw_i.$$

w_1, \dots, w_k 를 잠재 변수로 사후 분포에 추가하면

$$\pi(\theta, w_1, \dots, w_k) \propto \prod_{i=1}^k I(0 \leq w_i \leq f_i(\theta)).$$

$$\pi(\theta) \propto \int \dots \int \pi(\theta, w_1, \dots, w_k) dw_1 \dots dw_k$$

이므로, $\pi(\theta)$ 는 $(\theta, w_1, \dots, w_k) \sim \pi(\theta, w_1, \dots, w_k)$ 일 때 θ 의 주변 분포이다.

깁스 알고리즘

- $w_i, i = 1, 2, \dots, k$ 의 완전 조건부 밀도 함수

$$\pi(w_i | w_{-i}, \theta) \propto I(0 \leq w_i \leq f_i(\theta)) \propto U(0, f_i(\theta))$$

- θ 의 완전 조건부 밀도함수

$$\pi(\theta | w) \propto \prod_{i=1}^k I(f_i(\theta) \geq w_i) \propto U(A)$$

$$A = \{\theta : f_i(\theta) \geq w_i, i = 1, \dots, k\}$$

예. 절단된 정규분포

$$\pi(x) \propto e^{-\frac{1}{2\sigma^2}(x-\mu)^2} I(x \geq A), A \in \mathbb{R}$$

라 하자. π 를 정상분포로 갖는 마르코프 체인 $x^{(t)}$ 을 생성하고자 한다.

아이디어

$$\pi(x) \propto \int I(0 \leq z \leq e^{-\frac{1}{2\sigma^2}(x-\mu)^2}) I(x \geq A) dz$$

이라는 것에 착안해서,

$$\pi(x, z) \propto I(0 \leq z \leq e^{-\frac{1}{2\sigma^2}(x-\mu)^2}) I(x \geq A)$$

이라 놓는다. $\pi(x, z)$ 를 정상분포로 갖는 마르코프 체인 $(x^{(t)}, z^{(t)})$ 를 생성하면, $x^{(t)}$ 는 $\pi(x)$ 를 정상분포로 갖는 마르코프체인이 된다.

그룹화 깃스추출법과 붕괴 깃스추출법

알고리즘 1. 원형의 깃스추출법

- (i) $\theta_1 \sim \pi(\theta_1 | \theta_2, \theta_3)$
- (ii) $\theta_2 \sim \pi(\theta_2 | \theta_1, \theta_3)$
- (iii) $\theta_3 \sim \pi(\theta_3 | \theta_1, \theta_2)$

알고리즘 2. 그룹 깃스 추출법

- (i) $(\theta_1, \theta_2) \sim \pi(\theta_1, \theta_2 | \theta_3)$
- (ii) $\theta_3 \sim \pi(\theta_3 | \theta_1, \theta_2)$

몇 개의 변수를 묶어서 한 개의 변수로
본 알고리즘이다.

알고리즘 3. 붕괴 깃스추출법

- (i) $(\theta_1, \theta_2) \sim \pi(\theta_1, \theta_2)$
- (ii) $\theta_3 \sim \pi(\theta_3 | \theta_1, \theta_2)$

그룹 깃스추출법에서 조건부 분포 대신
주변 분포를 사용했다. $\theta(t)$ 들은 서로
독립이 된다.

알고리즘 4. 수정된 붕괴 깃스추출법

(i) $\theta_1 \sim \pi(\theta_1 | \theta_2)$

(ii) $\theta_2 \sim \pi(\theta_2 | \theta_1)$

(iii) $\theta_3 \sim \pi(\theta_3 | \theta_1, \theta_2)$

그룹 깃스추출법에서 (i) 단계에 깃스추출법을 적용한 것이다.

속도는 붕괴 깃스추출법 > 그룹 깃스추출법 > 본래 깃스추출법의 순으로 빠르다.

수정된 붕괴 깃스추출법은 붕괴 깃스추출법 보다는 느릴 것이다.

다음시간

10강

메트로폴리스

